ESCUELA COLOMBIANA DE INGENIERÍA JULIO GARAVITO
DEPARTAMENTO DE INGENIERÍA DE SISTEMAS

JardinerIA

Proyecto de curso PTIA

Entrega 2 – Hito 2: Problema y avance de la solución

Grupo 02

Integrantes:
Juan Esteban Laverde Mesa

Fecha de entrega: Octubre de 2026

Declaración firmada

“Declaro que he escrito este trabajo de investigación por mí mismo, y que no he utilizado otras fuentes o recursos que los indicados para su preparación. Declaro que he indicado claramente todas las citas directas e indirectas, y que este documento no se ha presentado en otro lugar para fines de examen o publicación”

Nombre del estudiante & Firma:

_____
Juan Esteban Laverde Mesa

Fecha: ____ de _____ de 2026

Índice de contenido

1. Introducción

2. Trabajos relacionados

3. Descripción del problema

4. Justificación

5. Alcance y objetivos

6. Diseño metodológico

Referencias

Las secciones 1 a 4 corresponden al Hito 1 (corregidas y completadas según los lineamientos); las secciones 5 y 6 son las nuevas de este Hito 2.

1. Introducción

1.1 Contexto

La jardinería doméstica está ganando terreno entre las generaciones más jóvenes. Según la encuesta *2024 Gardening Outlook* de Axiom Marketing (2023), realizada en Estados Unidos, el 52,7 % de los encuestados de la generación Z y el 53,5 % de la generación Y (millennials) gastaron más dinero en jardinería en 2023 que en 2022, y el 71,2 % y el 76,2 %, respectivamente, planeaban sembrar más o ampliar su jardín en 2024. Aunque son cifras de otro país, muestran una tendencia de demanda que justifica explorar herramientas para este público.

Las técnicas que la humanidad ha desarrollado durante siglos para cuidar sus cultivos siguen vigentes. Sin embargo, como en otros campos, las nuevas tecnologías pueden complementarlas y mejorar los resultados, y ahí es donde entra **JardinerIA**: una herramienta de apoyo para quien cultiva en casa, no un reemplazo de su criterio.

A la jardinería de autocultivo se le suelen asociar beneficios como el bienestar y la reducción del estrés al ver crecer las propias plantas, un posible ahorro en la compra de alimentos y, cuando hay plantas con flor, un aporte a los polinizadores. Por eso, una herramienta que facilite el proceso y deje a la persona usuaria la autonomía de decidir sobre sus cultivos —para conservar la satisfacción de hacerlo— es una idea pertinente para desarrollar durante el semestre.

1.2 Tres problemas que interesaría resolver

1. **Anticipar el estado y los cuidados de una planta de autocultivo** a partir de un reporte diario breve del usuario (problema que da origen a JardinerIA).
2. **Diagnosticar enfermedades o plagas** de plantas a partir de fotografías de las hojas tomadas con el celular.
3. **Optimizar el riego en huertas urbanas** para ahorrar agua, usando datos de humedad del suelo y clima.

1.3 ¿Por qué como proyecto de PTIA?

Los tres problemas comparten rasgos propios de la inteligencia artificial: hay **incertidumbre** (dos plantas iguales reaccionan distinto), las decisiones dependen de **patrones aprendibles a partir de datos** y requieren combinar **conocimiento experto** (qué necesita cada especie) con **razonamiento sobre evidencia parcial** (lo que el usuario observa). Permiten aplicar lo visto en el curso —clasificación supervisada, redes neuronales y su evaluación con métricas— y obligan a considerar aspectos éticos y de diseño responsable: explicar las recomendaciones, comunicar la incertidumbre, cuidar los datos del usuario y respetar su autonomía.

2. Trabajos relacionados

Para cada problema se presentan dos trabajos con su tecnología y sus resultados, y se señala en qué se diferencian de lo que se propone aquí.

Problema 1: anticipar el estado y los cuidados de la planta

- **Planta (Planta AB).** Aplicación móvil de cuidado de plantas. Según su sitio oficial, sus algoritmos usan más de 30 parámetros junto con datos del clima local para avisar cuándo regar, fertilizar o trasplantar, e incluye medidor de luz, identificación por foto y un diagnóstico de plantas enfermas; reporta millones de usuarios (Planta AB, s. f.). *Diferencia:* programa tareas según la especie y el entorno, pero no documenta que estime la evolución futura del estado de la

planta a partir de lo que el usuario observa cada día. Las cifras de uso son declaradas por el desarrollador, no evaluadas de forma independiente.

- **Singh et al. (2016).** Revisión sobre aprendizaje automático para identificar estrés en plantas. Propone cuatro etapas de decisión: identificación, clasificación, cuantificación y **predicción**. La tecnología son imágenes y sensores de alto rendimiento en contextos de investigación. *Diferencia:* respalda que predecir el estrés es una tarea distinta y viable, pero requiere instrumentación que un aficionado no tiene.

Problema 2: diagnóstico de enfermedades por foto

- **Mohanty et al. (2016).** Red neuronal convolucional entrenada con 54 306 imágenes de hojas (14 cultivos, 26 enfermedades). Alcanzó 99,35 % de exactitud en un conjunto de prueba retenido, pero en imágenes tomadas en condiciones distintas a las de entrenamiento la exactitud cayó a 31,4 % (versión en arXiv), lo que muestra que el desempeño depende mucho de la similitud entre los datos de entrenamiento y los de uso real.
- **Hughes y Salathé (2015).** Repositorio abierto de imágenes de salud de plantas (PlantVillage), creado para desarrollar diagnóstico móvil de enfermedades; es la base del trabajo anterior. *Diferencia con el proyecto:* ambos dependen de grandes conjuntos de imágenes y de modelos de visión; son un buen enfoque, pero reactivo (diagnostica cuando el daño ya es visible).

Problema 3: riego eficiente en huertas urbanas

- **Goap et al. (2018).** Sistema de manejo de riego basado en IoT, aprendizaje automático y tecnologías de código abierto que predice los requerimientos de riego de un campo a partir de datos sensados.
- **Alanya-Arango et al. (s. f.).** Sistema de riego inteligente en el que sensores IoT capturan datos atmosféricos y del suelo, se envían a la nube y modelos de aprendizaje automático recomiendan el tratamiento al agricultor. *Diferencia con el proyecto:* ambos requieren sensores y hardware, y ponen el foco en el campo agrícola más que en el aficionado urbano.

Síntesis y relación con JardinerIA

Los enfoques de agricultura de precisión combinan sensores, drones y satélites; por ejemplo, el proyecto iDRONE del centro AINIA integra sensores hiperespectrales en drones y robots con inteligencia artificial y analítica de datos (Interempresas, s. f.). Son soluciones pensadas para una escala profesional. JardinerIA se enfoca en la jardinería urbana y el autocultivo: no cuenta con sensores ni drones y, en cambio, usa como fuente de datos el **reporte diario breve de la propia persona**, lo que mantiene bajo el costo, conserva su participación y permite anticipar problemas **antes** de que sean evidentes.

3. Descripción del problema

3.1 Criterios para seleccionar el problema

Se calificó cada problema de 1 a 5 con cinco criterios ponderados, elegidos a partir de lo que se espera del proyecto: que sea útil para una persona aficionada, que sea realizable en un semestre por un equipo pequeño, que existan datos con los que trabajar, que aporte algo distinto a lo que ya existe y que respete la autonomía de quien cultiva.

Criterio	Peso	P1: estado y cuidados	P2: enfermedades por foto	P3: riego eficiente
Relevancia para el aficionado urbano	20 %	5	4	3
Viabilidad técnica en el semestre (2 personas, sin hardware)	25 %	4	4	2
Disponibilidad de datos	20 %	2	5	3
Carácter preventivo y diferenciación frente a lo existente	20 %	5	2	3
Autonomía del usuario (apoyar sin reemplazar su decisión)	15 %	5	3	2
Puntaje ponderado (sobre 5)	100 %	4,15	3,65	2,60

Tabla 1. Matriz de selección (calificación del equipo; 1 = bajo, 5 = alto).

El Problema 1 obtiene el mayor puntaje principalmente por su carácter preventivo y por la autonomía que deja al usuario. Su debilidad es la **disponibilidad de datos** (no existe un conjunto público de reportes diarios de plantas), riesgo que se aborda en las secciones 5 y 6 con una base de conocimiento y datos simulados. El Problema 2 tiene datos abundantes, pero es reactivo y ya está cubierto por varias aplicaciones; el Problema 3 depende de hardware.

3.2 Problema seleccionado

Muchas veces, y sobre todo en los primeros intentos de autocultivo, un jardín casero no da el resultado esperado: incluso siguiendo recomendaciones paso a paso, la planta puede dejar de crecer, marchitarse o no dar frutos. Coloquialmente se conoce como “mala mano”, y las causas suelen ser difíciles de identificar para un principiante (exceso o falta de riego, poca luz, temperatura, plagas). Cuando esto ocurre, algunas personas desisten de la actividad.

El problema seleccionado es: **dado el historial reciente de reportes diarios de una planta y su especie, estimar su estado actual, anticipar si en los próximos días mejorará o empeorará, y recomendar los cuidados necesarios, explicando el porqué.** Con un reporte diario muy breve del usuario sobre el estado de la planta y las condiciones ambientales, el sistema le indica en qué estado se encuentra, qué cuidados puede requerir y si su situación podría cambiar; así la persona deja de estar a ciegas y mejora sus cuidados, y con el uso el modelo se vuelve más preciso.

4. Justificación

4.1 ¿Cuál es el gran problema que se quiere resolver?

Quien empieza a cultivar recibe instrucciones genéricas (“riega cada tres días”, “necesita buena luz”), pero cuando algo sale mal no tiene cómo saber **por qué** ni **qué hacer a tiempo**. La falta de retroalimentación interpretable convierte los errores de cuidado en frustración y, finalmente, en abandono de la actividad. El gran problema es esa brecha entre las instrucciones generales y el estado particular de cada planta en cada momento.

4.2 ¿Por qué es importante resolverlo?

- **Para la persona usuaria:** evita pérdidas de plantas, dinero y tiempo, y reduce la frustración que lleva a abandonar un pasatiempo que suele asociarse con bienestar.

- **Para el hogar y la ciudad:** sostener el autocultivo permite conservar los beneficios asociados (alimentos propios, espacios verdes, apoyo a polinizadores) y fomenta hábitos de consumo más conscientes.
- **Para el aprendizaje:** una herramienta que explica sus recomendaciones ayuda a la persona a entender su planta y a ganar criterio propio, en lugar de depender de ella.
- **Para la IA responsable:** es un caso donde la tecnología debe **recomendar y explicar, no decidir por el usuario**, comunicar su incertidumbre y usar la menor cantidad de datos personales posible.

5. Alcance y objetivos

5.1 Problema que efectivamente se va a resolver

De la visión general de la sección 3 se resolverá, en esta prueba de concepto, el siguiente subproblema:

- **Cultivos:** tres especies de autocultivo comestible de balcón o patio, como albahaca, lechuga y tomate cherry (selección propuesta, ajustable según la disponibilidad de información agronómica).
- **Entrada:** un reporte diario estructurado de 7 campos de respuesta rápida (humedad del sustrato, color de hojas, turgencia, riego realizado, horas de sol, temperatura ambiente y presencia de plagas) más la especie y los días desde la siembra.
- **Salida:** (a) estado actual (Saludable, Atención o Crítico), (b) tendencia a 3 días (Mejora, Estable o Empeora) con su nivel de confianza y (c) hasta dos acciones recomendadas con una explicación breve.
- **Canal:** aplicación web en español.

Queda fuera del alcance: diagnóstico por fotografías, sensores o hardware, identificación específica de plagas y enfermedades, predicción de cosecha, otras especies y aplicación móvil nativa.

5.2 ¿Por qué es una simplificación adecuada?

- **Conserva la esencia del problema:** sigue siendo anticipar el estado a partir de un reporte diario breve, que es la idea central de JardinerIA.
- **Reduce la fricción para el usuario:** un reporte de menos de un minuto con opciones predefinidas es algo que un aficionado puede sostener cada día.
- **Es realizable con los recursos disponibles:** con tres especies se puede construir y revisar una base de conocimiento manejable, y evitar fotografías y sensores elimina la necesidad de grandes conjuntos de imágenes y de hardware.
- **Es escalable:** agregar una especie consiste en incorporar su perfil a la base de conocimiento, sin rediseñar el sistema.

5.3 Objetivos

Objetivo general. Desarrollar una prueba de concepto de un sistema de inteligencia artificial que, a partir de un reporte diario breve, estime el estado de una planta de autocultivo, anticipe su tendencia a tres días y recomiende cuidados explicados, para tres especies, dejando las decisiones en manos del usuario.

Objetivos específicos.

1. Construir la base de conocimiento agronómico de las tres especies (rangos óptimos, síntomas, causas probables y acciones).
2. Generar un conjunto de datos simulado y un conjunto de escenarios revisados manualmente para entrenar y evaluar el modelo.

3. Entrenar y comparar modelos de clasificación de estado y de tendencia, y seleccionar el mejor según el desempeño en validación.
4. Implementar el servicio y la interfaz web que integren reglas, modelo y explicación.
5. Evaluar el sistema con las metas de la Tabla 2 y con personas usuarias.

Objetivo cuantitativo. Cumplir las metas de la Tabla 2.

Indicador	Meta	Cómo se medirá
Macro-F1 de la clasificación de estado (3 clases)	≥ 0,80	Conjunto de prueba, separado por planta
Recall de la clase “Crítico”	≥ 0,85	Conjunto de prueba (no dejar pasar plantas en riesgo)
Exactitud de la tendencia a 3 días (3 clases)	≥ 0,70	Conjunto de prueba (azar ≈ 0,33)
Concordancia de las recomendaciones con guías de cuidado	≥ 85 %	30 escenarios revisados contra guías de cuidado de cada especie
Tiempo para diligenciar el reporte diario	≤ 60 s	Promedio con al menos 5 personas usuarias
Tiempo de respuesta del sistema	≤ 2 s	Prueba local del servicio
Usabilidad (escala SUS)	≥ 70	Al menos 5 personas usuarias con el prototipo

Tabla 2. Metas cuantitativas del proyecto.

Objetivo cualitativo. Que la persona usuaria entienda por qué se le recomienda cada acción, perciba que conserva el control sobre su cultivo y sienta menos frustración al cuidar sus plantas.

Nota sobre la validez de las métricas: como no existe un conjunto público de reportes diarios, el entrenamiento inicial usará datos simulados con la base de conocimiento; por eso las métricas sobre esos datos miden la **coherencia con el conocimiento agronómico**, no el desempeño con plantas reales. Para reducir esta brecha se evaluarán además 30 escenarios revisados contra guías de cuidado y, si es posible, un piloto corto con personas usuarias reales.

6. Diseño metodológico

6.1 Estrategia general de la solución

Se propone un **sistema híbrido** que combina una base de conocimiento agronómico con un modelo de aprendizaje automático supervisado y una capa de explicación. La Tabla 3 resume las alternativas consideradas.

Estrategia	Ventajas	Limitaciones	Decisión
Solo reglas (sistema experto)	Transparente y no requiere datos	No aprende ni mejora con el uso; difícil cubrir interacciones entre variables	Descartada como única opción
Solo aprendizaje profundo con los reportes	Aprende patrones complejos	No hay datos reales suficientes; poco explicable	Descartada
Visión por computador con fotos	Aprovecha datasets públicos	Reactiva, exige fotos de buena calidad y no anticipa el estado	Fuera del alcance
Híbrido: conocimiento + aprendizaje automático	Arranca con conocimiento, mejora con la retroalimentación y puede explicarse	Requiere construir la base de conocimiento y el simulador	Seleccionada

Tabla 3. Alternativas de estrategia.

Justificación. No existe un conjunto de datos público de reportes diarios de plantas, por lo que un modelo puramente de datos no tendría con qué aprender al inicio; el conocimiento agronómico resuelve ese arranque. A la vez, el proyecto promete que el modelo “se vuelva más preciso” con el uso, algo que un sistema solo de reglas no logra. Finalmente, las explicaciones son necesarias para generar confianza y conservar la autonomía del usuario.

6.2 ¿Dónde se concentra la inteligencia de la solución?

- **Conocimiento:** perfiles por especie (rangos óptimos de humedad, luz y temperatura), relaciones síntoma → causa probable → acción, y umbrales de estado. Se construye a partir de guías de cuidado de cada especie.
- **Razonamiento:** (1) el motor de reglas calcula desviaciones respecto a los rangos y propone causas; (2) el modelo ML combina esas señales con la evolución de los últimos días para estimar estado y tendencia; (3) el generador de recomendaciones elige las acciones que atienden la causa más probable.
- **Aprendizaje:** el usuario confirma si la tendencia anunciada se cumplió; esa respuesta se guarda como nueva etiqueta y alimenta el reentrenamiento periódico del modelo.

La mayor parte de la “inteligencia” se concentra en el modelo ML y en su interacción con la base de conocimiento.

6.3 Herramientas seleccionadas

Elemento	Herramienta	Justificación
Lenguaje y datos	Python, pandas y NumPy	Estándar para análisis de datos; es el que se usa en el curso
Modelos de línea base	scikit-learn (Random Forest y Gradient Boosting)	Funcionan bien con datos tabulares y pocos datos, y permiten ver la importancia de cada variable
Modelo comparativo	Keras (perceptrón multicapa)	Es el framework visto en el curso; permite comparar con los modelos de árboles
Servicio (backend)	FastAPI	Ligero, expone el modelo como API y genera documentación automática
Almacenamiento	SQLite	Sin servidor; suficiente para una prueba de concepto
Interfaz	Aplicación web responsive (HTML/JavaScript o Streamlit) y Figma para el prototipo	Rapidez de construcción y de iteración sobre el diseño
Clima (opcional)	API de clima gratuita (p. ej., Open-Meteo)	Evita pedir la temperatura al usuario
Control de versiones	Git / GitHub	Trazabilidad de las fuentes del diseño y del código

Tabla 4. Herramientas para implementar la solución.

6.4 Arquitectura de la solución

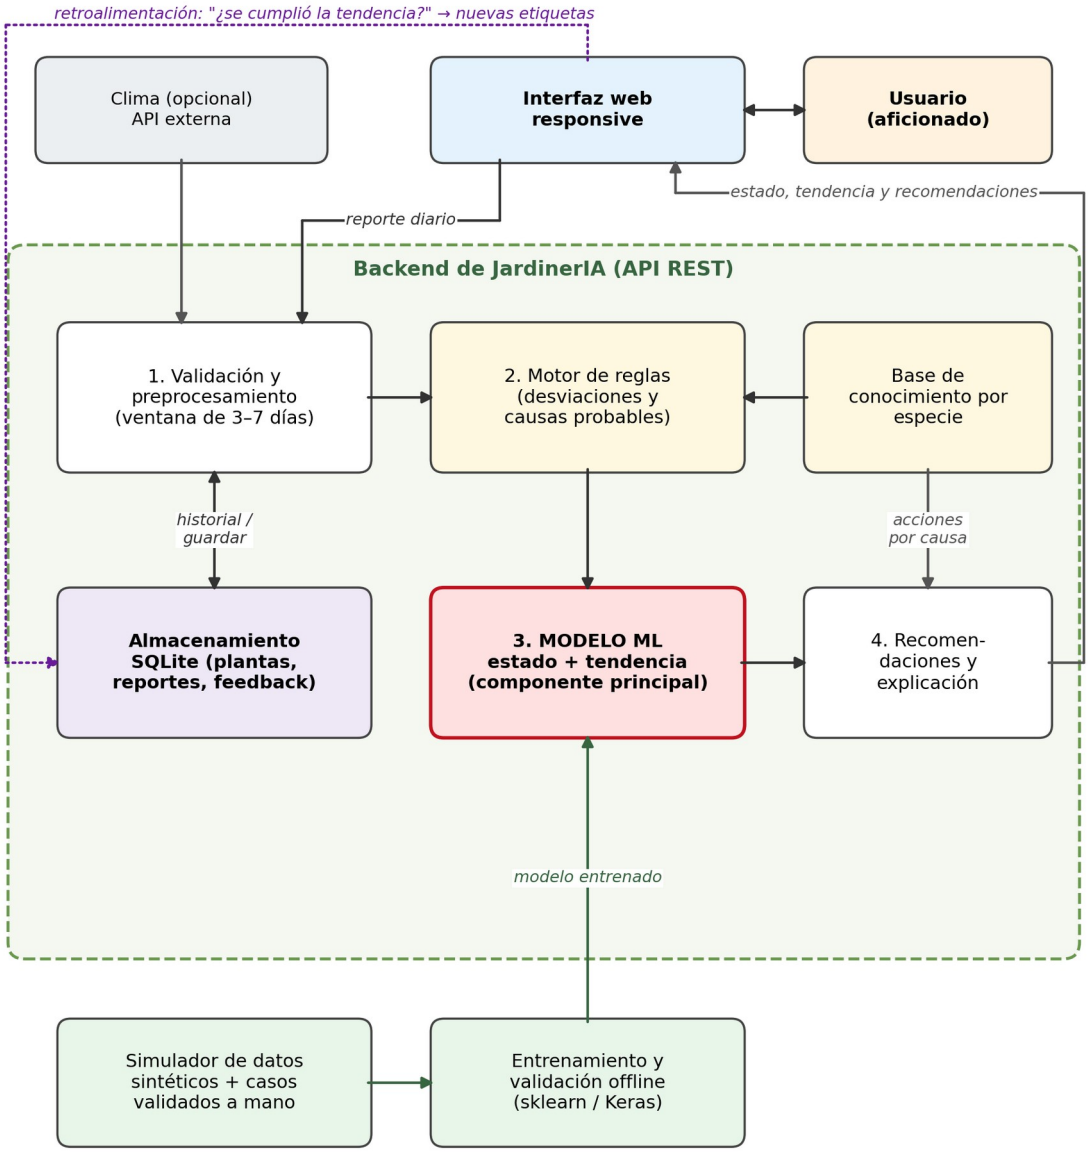


Figura 1. Arquitectura de JardinerIA: componentes y relaciones.

El usuario envía su reporte desde la interfaz web; el backend lo valida y lo complementa con el historial guardado, aplica el motor de reglas, estima estado y tendencia con el modelo y devuelve resultado y recomendaciones. La retroalimentación del usuario se almacena y, de forma offline, se usa para reentrenar el modelo.

Componente	Responsabilidad
1. Validación y preprocesamiento	Recibe el reporte, valida los campos y arma la ventana de los últimos 3–7 días con datos del almacenamiento.
2. Motor de reglas	Compara el reporte con los rangos de la especie y propone causas probables (p. ej., riego en exceso).
3. Modelo ML (principal)	Estima el estado actual y la tendencia a 3 días con su probabilidad.
4. Recomendaciones y explicación	Combina causa probable, tendencia y base de conocimiento para sugerir hasta dos acciones con una explicación breve.
Base de conocimiento	Perfiles por especie: rangos de humedad, luz y temperatura, síntomas, causas y acciones.
Almacenamiento	Guarda plantas, reportes, resultados y la retroalimentación del usuario.
Simulador y entrenamiento (offline)	Genera datos, entrena, valida y publica el modelo que usa el backend.

Tabla 5. Componentes de la arquitectura.

6.5 Componente principal: modelo de estado y tendencia

Es el componente que estima, para cada planta y día, **cómo está** y **hacia dónde va**. Se describe a continuación.

Entradas. Los siete campos del reporte (Tabla 6), la especie y los días desde la siembra, más variables derivadas calculadas sobre la ventana de 3–7 días: cambio de humedad entre días, días desde el último riego, promedio de horas de sol y desviación de cada variable respecto al rango óptimo de la especie. Las categorías ordinales se codifican como enteros y las nominales como variables indicadoras.

Campo	Valores	Tipo
Humedad del sustrato	Seco / Húmedo / Encharcado	Categórica ordinal
Color de hojas	Verde normal / Amarillas / Puntas marrones / Manchas	Categórica
Turgencia	Firme / Caída leve / Marchita	Categórica ordinal
Riego realizado hoy	No / Poco / Suficiente / Exceso	Categórica ordinal
Horas de sol	0 a 12 h (estimadas)	Numérica
Temperatura ambiente	°C (manual o automática)	Numérica
Plagas visibles	Sí / No	Binaria

Tabla 6. Campos del reporte diario.

Salidas. (1) Estado actual: Saludable, Atención o Crítico. (2) Tendencia a 3 días: Mejora, Estable o Empeora. Ambos con probabilidad; si la confianza es baja, la interfaz lo indica en lugar de afirmar.

Datos de entrenamiento. Un simulador sencillo de balance hídrico y estrés (humedad del sustrato según riego, luz y temperatura) genera trayectorias diarias de plantas virtuales de cada especie, a las que se agrega ruido para imitar reportes subjetivos. El estado se etiqueta con umbrales sobre un índice de estrés definido con la base de conocimiento, y la tendencia se obtiene comparando el estado del día con el de tres días después.

Entrenamiento y selección. Se compararán Random Forest, Gradient Boosting y un perceptrón multicapa en Keras. La partición en entrenamiento, validación y prueba se hace **por planta (trayectoria) y no por día**, para evitar que días de una misma planta aparezcan en entrenamiento y prueba. Se reportan macro-F1, recall por clase y matriz de confusión, y se prioriza el recall de la clase "Crítico".

Aprendizaje con el uso. Cada confirmación del usuario sobre si la tendencia se cumplió se guarda como un ejemplo real; cuando se acumulan suficientes, se reentrena y se compara con la versión actual antes de reemplazarla.

Riesgos y mitigación.

- *Brecha entre datos simulados y reales:* evaluación con 30 escenarios revisados, piloto con usuarios y reentrenamiento con datos reales.
- *Reportes subjetivos o inconsistentes:* opciones predefinidas con ejemplos visuales y ruido de observación en la simulación.
- *Recomendaciones erróneas:* el sistema sugiere y explica, no actúa; muestra su confianza y recomienda consultar fuentes especializadas cuando es baja.
- *Privacidad:* se guardan solo datos de las plantas y las respuestas del reporte, sin datos personales sensibles.

6.6 Prototipo de interfaz

El prototipo de interfaz (navegable, con simulación de las funciones aún no implementadas) contempla cinco pantallas:

1. **Mis plantas:** lista de plantas con su estado actual (semáforo) y un botón para agregar una nueva.
2. **Reporte diario:** formulario de siete campos con botones grandes y opciones predefinidas, pensado para completarse en menos de un minuto.
3. **Resultado:** estado actual, tendencia a 3 días con su confianza y hasta dos acciones recomendadas con la explicación del porqué.
4. **Historial:** gráfico de la evolución del estado y de los reportes pasados.
5. **Retroalimentación:** pregunta de seguimiento ("¿se cumplió lo previsto?") que alimenta el aprendizaje del modelo.

Referencias

Alanya-Arango, J., Alanya-Beltran, J., Ravichandran, S. K., Singh, B., Sasi, A., & Gangodkar, D. (s. f.). *Internet of Things and machine learning based intelligent irrigation system for agriculture*. IEEE. https://archives.christuniversity.in/items/show/20103

Axiom Marketing. (2023, 31 de octubre). *Axiom releases annual 2024 gardening outlook survey* [Comunicado de prensa]. Business Wire. https://www.businesswire.com/news/home/20231031325725/en/

Goap, A., Sharma, D., Shukla, A. K., & Krishna, C. R. (2018). An IoT based smart irrigation management system using machine learning and open source technologies. *Computers and Electronics in Agriculture, 155*, 41–49. https://doi.org/10.1016/j.compag.2018.09.040

Hughes, D. P., & Salathé, M. (2015). *An open access repository of images on plant health to enable the development of mobile disease diagnostics*. arXiv. https://arxiv.org/abs/1511.08060

Interempresas. (s. f.). *iDRONE: drones e inteligencia artificial para mejorar rendimientos en el campo*. https://www.interempresas.net/Horticola/256196-iDRONE-drones-e-inteligencia-artificial-para-mejorar-rendimientos-en-el-campo.html

Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). Using deep learning for image-based plant disease detection. *Frontiers in Plant Science, 7*, 1419. https://doi.org/10.3389/fpls.2016.01419

Planta AB. (s. f.). *Planta: Keep your plants alive* [Sitio web]. https://getplanta.com/

Singh, A., Ganapathysubramanian, B., Singh, A. K., & Sarkar, S. (2016). Machine learning for high-throughput stress phenotyping in plants. *Trends in Plant Science, 21*(2), 110–124. https://doi.org/10.1016/j.tplants.2015.10.015